

Cours : K-Means

Apprentissage non supervisé – Clustering

K. Kadri

Plan

- 1 Introduction au clustering
- 2 Intuition de K-Means
- 3 Algorithme K-Means
- 4 Choisir K : Méthodes
- 5 Avantages limites

Qu'est-ce que le clustering ?

- Objectif : regrouper des points “semblables” sans labels.
- Créer des groupes appelés **clusters**.
- Applications :
 - segmentation client,
 - compression d'images,
 - détection d'anomalies,
 - pré-traitement en ML supervisé.

Apprentissage non supervisé

Pas de vérité terrain → on cherche la structure cachée dans les données.

Intuition : regrouper les points par proximité

- On veut former K clusters.
- Chaque cluster a un **centre** : le **centroïde**.
- Les points sont affectés au centroïde le plus proche (distance euclidienne).

Idée clé

Minimiser la distance totale entre les points et leur centroïde.

Étapes de l'algorithme

- 1 Choisir K centres initiaux (aléatoires ou k-means++).
- 2 Assignment : chaque point \rightarrow centroïde le plus proche.
- 3 Mise à jour : recalculer chaque centroïde (moyenne des points assignés).
- 4 Répéter 2–3 jusqu'à convergence.

Convergence

Quand les centroïdes ne bougent plus ou très peu.

Inertie (Within-Cluster Sum of Squares)

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

- x_i : un point
- C_k : cluster k
- μ_k : centroïde du cluster

Objectif

Minimiser $J \rightarrow$ clusters compacts et homogènes.

Méthode du coude (Elbow method)

- On calcule l'inertie pour plusieurs valeurs de K .
- On cherche un point où la diminution ralentit fortement.

Interprétation

Avant le coude : ajouter un cluster améliore beaucoup. Après le coude : amélioration marginale
→ K optimal.

Définition

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

- $a(i)$: distance intra-cluster,
- $b(i)$: distance au cluster le plus proche.
- $s(i) \in [-1, 1]$.

Bonne valeur

Plus s est proche de 1 \rightarrow meilleur clustering.

Avantages de K-Means

- Simple à comprendre et à implémenter.
- Très rapide (scalable).
- Bon pour les données bien séparées en formes sphériques.

Cas d'usage

Segmentation client, quantification couleur, partitionnement rapide.

- Nécessite de fixer K .
- Suppose des clusters “ronds”.
- Sensible aux outliers.
- Peut converger vers un mauvais optimum (solution locale).

Solution pratique

Utiliser l'init k-means++ et plusieurs random states.